

Machine Learning

Modélisation et prédiction des salaires

Master 2 Economie parcours Expertise et Analyse de Données Economiques

ELMI - Graduate School of Economics and Management

Université Côte d'Azur, France

Par Loua Aurel VEHI

Année universitaire : 2024 - 2025

Intitulé du cours : **Collecte, traitement et analyse des données en Python**

Professeur : **Joeffrey Drouard**

Sommaire

Introduction.....	1
Présentation du dataset.....	1
Prétraitement des données.....	2
Sélection des caractéristiques et paramétrage.....	3
Résultats	4
1. Linear regressinon.....	4
2. Random Forest Regressor	4
Conclusion	4

Introduction

Dans un monde où les données jouent un rôle central dans la prise de décision, l'analyse prédictive s'impose comme un outil incontournable pour estimer avec précision des variables d'intérêt. Ce projet s'inscrit dans cette dynamique en mettant en œuvre des techniques de Machine Learning pour prédire les salaires en USD à partir d'un ensemble de données.

L'objectif est d'identifier le modèle prédictif le plus performant permettant d'estimer le salaire d'un individu en fonction de plusieurs caractéristiques professionnelles et organisationnelles. Pour cela, deux algorithmes de régression seront étudiés : **Linear Regression (LR)** et **Random Forest Regressor (RF)**. La qualité des prédictions sera quant à elle évaluée à l'aide du coefficient de détermination (R^2) sur un ensemble de test.

Le dataset exploité comprend plusieurs variables décrivant le contexte professionnel des employés, telles que leur expérience ou encore le type d'emploi. Grâce à ces informations, nous chercherons à déterminer quels facteurs influencent le plus les salaires et à construire un modèle robuste capable d'effectuer des prédictions fiables.

Présentation du dataset

Le jeu de données *training.csv* (dossier *data*) contient des informations sur les salaires d'employés exerçant différents métiers à travers plusieurs pays. Il contient 3004 observations et 9 variables, combinant des données numériques et catégoriques. La variable principale, **salary_in_usd**, représente les salaires annuels et varie entre 5000 et 450 000 US\$. La majorité des salaires se situe entre 50 000 et 150 000 US\$, avec quelques valeurs extrêmes au-delà de 300 000 US\$. Les données montrent que les grandes entreprises offrent en général des salaires plus élevés que les petites, bien que les écarts restent modérés entre entreprises de taille moyenne et grande. Le niveau d'expérience a une forte influence sur les salaires, les experts étant les mieux rémunérés, suivis par les professionnels confirmés, les intermédiaires et enfin les débutants.

Les postes à temps plein offrent les meilleures rémunérations par rapport aux contrats à temps partiel ou freelance. Les emplois 100 % en télétravail offrent des salaires compétitifs, souvent

comparables à ceux nécessitant une présence sur site. Au niveau géographique, les États-Unis affichent les salaires moyens les plus élevés, suivis d'Israël et du Canada. Les économies émergentes se situent à des niveaux de rémunération nettement inférieurs. Enfin, en termes de postes, certains intitulés comme *Data Science Tech Lead* ou *Director of Data Science* affichent des salaires moyens dépassant 200 000 US\$, ce qui reflète leur importance stratégique dans les organisations.

Prétraitement des données

Le prétraitement des données est une étape fondamentale pour assurer la qualité et la cohérence des informations utilisées par le modèle. Pour ce faire, un pipeline nommé **preprocessor** (*pipeline.py*) est utilisé. Dans ce pipeline, la première action consiste à vérifier la présence des colonnes essentielles nécessaires à l'analyse. Si certaines colonnes manquent, une erreur est signalée afin d'éviter tout traitement incorrect. Une attention particulière est portée aux intitulés des postes, qui sont regroupés en catégories spécifiques pour faciliter l'analyse.

Les données manquantes sont ensuite imputées de manière méthodique. Pour les variables numériques, la médiane est utilisée comme valeur de remplacement, tandis que les variables catégorielles sont complétées avec la modalité la plus fréquente. Les variables catégorielles clés sont transformées à l'aide d'un encodage basé sur les moyennes des salaires observés, ce qui permet de capturer des relations importantes entre ces variables et la cible. Une nouvelle variable, **company_job_size**, est également introduite. Elle combine des informations sur la taille de l'entreprise, le titre du poste, la localisation et le niveau d'expérience, fournissant ainsi une mesure supplémentaire pour enrichir les prédictions.

Pour garantir l'uniformité des données, toutes les variables sont standardisées via une normalisation MinMax afin de se situer sur une même échelle. Ce processus est essentiel pour que le modèle ne soit pas influencé par des différences d'amplitudes entre les variables. Une étape supplémentaire enrichit les données en créant des interactions polynomiales de degré 2, ce qui permet de modéliser des relations non linéaires complexes.

Enfin, tout le pipeline est sauvegardé lors de l'entraînement, ce qui assure une parfaite reproductibilité des transformations appliquées. Lors de l'utilisation pour de nouvelles données, le pipeline déjà sauvegardé est chargé et appliqué, garantissant ainsi une cohérence totale entre l'entraînement et la prédiction.

Sélection des caractéristiques et paramétrage

Dans cette démarche, nous avons utilisé une combinaison de **LassoCV** et de tests par validation croisée pour identifier les meilleures combinaisons de variables explicatives.

La méthode **LassoCV**, avec une validation croisée à 5 plis, a permis de sélectionner les variables les plus pertinentes en supprimant celles dont les coefficients dans le modèle étaient nuls. Les variables retenues à cette étape constituent les bases de notre analyse et sont stockées dans une liste appelée features.

À partir de ces variables sélectionnées, nous avons généré toutes les combinaisons possibles de groupes de quatre variables. Chaque combinaison a été testée de manière systématique en utilisant un modèle de régression linéaire avec validation croisée. Pour chaque combinaison, le modèle a été évalué selon deux critères principaux : la moyenne des scores de validation croisée (R^2) et la performance « out-sample » sur un ensemble de test indépendant.

Seules les combinaisons présentant une moyenne des scores de validation croisée supérieure à 0,3 ont été conservées. Ces combinaisons ont ensuite été enregistrées avec leurs scores moyens, leur écart type et leur performance sur l'ensemble de test. Les résultats sont résumés dans un tableau permettant de comparer les combinaisons testées. Ce processus a permis d'identifier la combinaison optimale de variables explicatives à utiliser pour entraîner le model LR :

**company_location - work_year experience_level_SE - company_location
job_groups_Scientist - employment_type_FT job_groups_Engineer**

Quant au RF, un modèle initial de régression a d'abord été entraîné avec des paramètres prédéfinis. Par la suite, une recherche exhaustive des meilleurs hyperparamètres a été réalisée à l'aide de la méthode **GridSearchCV**. Cette technique permet de tester différentes combinaisons de paramètres en utilisant une validation croisée à cinq plis, garantissant ainsi une évaluation robuste.

Trois hyperparamètres clés ont été explorés : le nombre d'arbres dans la forêt, la profondeur maximale des arbres et le nombre minimum d'échantillons requis pour diviser un nœud. Ces paramètres influencent la capacité du modèle à capturer les relations dans les données tout en évitant un surapprentissage. Différentes valeurs ont été testées pour chacun d'eux, et les résultats

obtenus pour chaque combinaison ont été comparés en fonction du score R^2 . Cette configuration optimale a permis d'améliorer la capacité du modèle à généraliser sur de nouvelles données :

```
{'max_depth': 10, 'min_samples_split': 10, 'n_estimators': 400}
```

Résultats

1. Linear regressinon

La meilleure combinaison a obtenu un score moyen de **0.3151** en validation croisée, avec un écart type de **0.0368**, et un score « out-sample » de **0.31**. Ces résultats montrent une capacité moyenne du modèle à expliquer la variance des données, avec une certaine stabilité dans les performances.

2. Random Forest Regressor

Le score moyen R^2 en validation croisée est de **0.4036**, indiquant que le modèle explique environ 40 % de la variance des données d'entraînement. Cependant, sur l'ensemble de test, le score "out-sample" est légèrement inférieur, à **0.29**, ce qui révèle une capacité moyenne de généralisation.

Conclusion

Cette étude a exploré la modélisation des salaires en US\$ à l'aide de techniques de Machine Learning, en comparant les performances de la régression linéaire et du Random Forest Regressor. Après un prétraitement rigoureux des données et une sélection optimisée des caractéristiques, les résultats montrent que la régression linéaire atteint un score R^2 moyen de 0.3151 en validation croisée et de 0.31 sur l'ensemble de test, tandis que le Random Forest Regressor obtient respectivement 0.4036 et 0.29. Bien que le modèle RF capture mieux les relations dans les données d'entraînement, sa généralisation reste modérée. Ces résultats soulignent l'importance du choix des variables et de l'optimisation des hyperparamètres pour améliorer la prédiction des salaires.